多帧点云联合配准

该配准方法来源于文献“Joint Alignment of Multiple Point Sets with Batch and Incremental Expectation-Maximization”中，核心思想是假设采集所得多帧点云的数据是从同一个高斯混合模型中进行多次采样及不同刚体变换所得，进而通过优化高斯高斯模型的参数及刚体变换矩阵实现多帧点云联合配准。

问题描述及模型介绍

假定一共采集到M帧3维点云数据，其中第j帧数据表示为$\mathbf{V}_j=[\boldsymbol{v}_{j1},\cdots,\boldsymbol{v}_{jN_j}]\in\mathbb{R}^{3\times N_j}$，而所有$M$帧点云数据的集合表示为$\mathbf{V}=\{\mathbf{V}_j\}_{j=1}^M$。接着，我们定义每一帧数据相对于真实坐标系的刚体变换矩阵为：$\{\Phi_j:\mathbb{R}^3\to\mathbb{R}^3\}_{j=1}^M$，它一般由两个量共同组成，即旋转矩阵和平移向量，多帧点云的配准就是通过估计这些变换矩阵来实现的。这边需要注意的是真实坐标系指的是高斯混合模型所在坐标系，即是一个虚拟的坐标系，有别于现有的一些将某一帧原始点云所在坐标系当作是真实坐标系的方法，因而可避免因数据噪声对结果造成的偏差。

为对被测物体点云进行表征，假定点云服从如下高斯混合模型，即

$$P(\boldsymbol{v}_{ji})=\sum_{k=1}^K\pi_k\mathcal{N}(\mathbf{T}_jv_{ji}+\boldsymbol{s}_j;\boldsymbol{\mu}_k,\boldsymbol{\Sigma}_k)+\pi_{k+1}\mathcal{U}(h)$$

其中$\mathbf{T}_j\in\mathbb{R}^3\times\mathbb{R}^3$表示旋转矩阵，$\boldsymbol{s}_j\in\mathbb{R}^3$为平移向量，所以有$\Phi_j(\boldsymbol{v}_{ji})=\mathbf{T}_j\boldsymbol{v}_{ji}+\boldsymbol{s}_j$；$\{\pi_k\}_{k=1}^{K+1}$表示模型不同组分之间的混合比例，且有$\sum_{k=1}^{K+1}\pi_k=1$;$\boldsymbol{\mu}_k\in\mathcal{R}^3$和$\boldsymbol{\Sigma}_k=\sigma_k\mathbf{I}_3\in\mathbb{R}^{3\times3}$分别表示模型每一组分的均值向量和方差矩阵；$\mathcal{U}(h)$是一个包围所有数据点的3维凸集合中的均匀分布，用于表示数据中的奇异值或噪点。其实这个模型从严格意义上说并不是一个高斯混合模型，因为其中有一个均匀分布项，但是为了方便描述，这边就还是以高斯混合模型来表述。基于此，定义一个系数γ来表示噪点与有效数据点之间的比例，即

$$\gamma=\frac{\pi_{K+1}}{\sum_{k=1}^K\pi_k}$$

这样我们便可通过控制这个系数的大小来平衡数据中奇异值与有效值的比例，以实现更有效的配准。

基于上述模型定义，模型中所有参数用$\boldsymbol{\Theta}$进行表示，即

$$\boldsymbol{\Theta}=\{\{\pi_k,\boldsymbol{\mu}_k,\boldsymbol{\Sigma}_k\}_{k=1}^K,\{\mathbf{T}_j,\boldsymbol{s}_j\}_{j=1}^M\}$$

与常规高斯混合模型的优化方法类似，这边也利用EM算法来对参数进行优化。为此，需引入潜变量$\mathcal{Z}=\{Z_{ji}|j\in[1,\cdots,M],i\in[1,\cdots,N_j]\}$，其中$Z_{ji}=k$表示第$j$帧点云中的第$i$个点$\boldsymbol{v}_{ji}$来源于模型的第$k$个组分。这样，我们便可通过交替E步和M步来实现参数$\boldsymbol{\Theta}$的优化。下面对E步和M步进行详述。

E步:

这一步是假定模型参数已知的情况下来估计潜变量的概率，即每一数据点归属于混合模型中某一组分的概率，用α_{jik}来进行表示：

$$\alpha_{jik}=P(Z_{ji}=k|\boldsymbol{v}_{ji};\boldsymbol{\Theta}^q)$$

其中$\boldsymbol{\Theta}^q$表示第q次迭代后模型参数的估计值，则α_{jik}可由如下公式计算得到

$$\alpha_{jik}=\frac{\beta_{jik}}{\sum_{s=1}^K\beta_{jis}+\frac{\gamma}{h(\gamma+1)}}$$

其中，$\frac{\gamma}{h(\gamma+1)}$用于表示数据中的噪点成分，而$\beta_{jik}$可用如下公式计算所得

$$\beta_{jik}=\frac{\pi_k}{\sigma_k^{3/2}}exp(\frac{-||\mathbf{T}_j\boldsymbol{v}_{ji}+\boldsymbol{s}_j-\boldsymbol{\mu}_k||^2}{2\sigma_k})$$

M步:

这一步是在假定α_{jik}已知的情况下来估计$\boldsymbol{\Theta}$，通过最大化如下目标函数实现

$$\begin{aligned}\mathcal{J}(\boldsymbol{\Theta}|\mathbf{V},\mathcal{Z})=\mathbb{E}_{\mathcal{Z}}[\log P(\mathbf{V},\mathcal{Z};\boldsymbol{\Theta})]&=\sum_{\mathcal{Z}}P(\mathcal{Z}|\mathbf{V};\boldsymbol{\Theta}^q)\log P(\mathbf{V},\mathcal{Z};\boldsymbol{\Theta})\\&=\sum_{j,i,k}\alpha_{jik}(\log\pi_k+\log P(\boldsymbol{v}_{ji}|Z_{ji}=k;\boldsymbol{\Theta}))\\&=-\frac{1}{2}\sum_{j,i,k}\alpha_{jik}(||\mathbf{T}_j\boldsymbol{v}_{ji}+\boldsymbol{s}_j-\boldsymbol{\mu}_k||^2_{\Sigma_k}+\log|\Sigma_k|-2\log\pi_k)\\&\quad+\log\pi_{K+1}\sum_{j,i}\alpha_{ji(K+1)}\end{aligned}$$

其中$|\cdot|$表示行列式运算，$||\boldsymbol{y}||^2_{\mathbf{A}}=\boldsymbol{y}^T\mathbf{A}^{-1}\boldsymbol{y}$。由于旋转矩阵需要满足一定的约束，上述优化问题进一步转换成下述约束优化问题

$$\begin{cases}\max_{\boldsymbol{\Theta}}f(\boldsymbol{\Theta})\\ s.t.\quad \mathbf{T}_j^T\mathbf{T}_j=\mathbf{I}_3\quad |\mathbf{T}_j|=1\quad \forall j\in[1,\cdots,M]\end{cases}\tag{a}$$

其中$f(\boldsymbol{\Theta})=\mathcal{J}(\boldsymbol{\Theta}|\mathbf{V},\mathcal{Z})$。这里的优化不同于一般的高斯混合模型，除了需要估计模型中每一组分的参数，即$\{\pi_k,\boldsymbol{\mu}_k,\boldsymbol{\Sigma}_k\}_{k=1}^K$，还需要估计刚体变换矩阵，即$\{\mathbf{T}_j,\boldsymbol{s}_j\}_{j=1}^M$。因此，这里的M步分为两个子步骤进行，先估计刚体变换矩阵，再估计每一组分的参数。

首先，为估计刚体变换矩阵，可通过对公式(a)进行分析转化得到如下约束优化问题

$$\begin{cases}\min_{\mathbf{T}_j,\boldsymbol{s}_j}||(\mathbf{T}_j\mathbf{W}_j+\boldsymbol{s}_j\boldsymbol{e}^T-\mathbf{M})\boldsymbol{\Lambda}_j||_F^2\\ s.t.\quad \mathbf{T}_j^T\mathbf{T}_j=\mathbf{I}_3\quad |\mathbf{T}_j|=1\end{cases}\tag{b}$$

其中$\boldsymbol{\Lambda}_j\in\mathbb{R}^{K\times K}$是一个主对角线上元素$\lambda_{jkk}=(\sum_{i=1}^{N_j}\alpha_{jik}/\sigma_k)^{1/2}$的对角矩阵，$\mathbf{M}=[\boldsymbol{\mu}_1,\cdots,\boldsymbol{\mu}_K]\in\mathbb{R}^{3\times K}$，$\boldsymbol{e}\in\mathbb{R}^K$是一个元素全为1的向量，$||\cdot||_F$表示一个矩阵的Frobenius范数，$\mathbf{W}_j=[\boldsymbol{w}_{j1},\cdots,\boldsymbol{w}_{jK}]\in\mathbb{R}^{3\times K}$，其中$\boldsymbol{w}_{jk}$表示第$j$帧点云来源于第$k$个组分的加权平均，即

$$\boldsymbol{w}_{jk}=\frac{\sum_{i=1}^{N_j}\alpha_{jik}\boldsymbol{v}_{ji}}{\sum_{i=1}^{N_j}\alpha_{jik}}$$

通过对上述优化问题进行推导，可获得$\mathbf{T}_j$及$\boldsymbol{s}_j$的解析解为

$$\begin{aligned}\mathbf{T}_j&=\mathbf{U}_j^l\mathbf{S}_j\mathbf{U}_j^r\\ \boldsymbol{s}_j&=\frac{1}{trace(\boldsymbol{\Lambda}_j^2)}(\mathbf{M}-\mathbf{R}_j\mathbf{W}_j)\boldsymbol{\Lambda}_j^2\boldsymbol{e},\quad \forall j\in[1,\cdots,M]\end{aligned}$$

其中$\mathbf{U}_j^l$和$\mathbf{U}_j^r$分别表示对矩阵$\mathbf{M}\boldsymbol{\Lambda}_j\mathbf{P}_j\boldsymbol{\Lambda}_j\mathbf{W}_j^T$进行奇异值分解后的左右奇异矩阵，且有$\mathbf{P}_j=\mathbf{I}_3-\frac{\boldsymbol{\Lambda}_j\boldsymbol{e}\boldsymbol{e}^T\boldsymbol{\Lambda}_j}{\boldsymbol{e}^T\boldsymbol{\Lambda}_j\boldsymbol{e}}$是映射矩阵，$\mathbf{S}_j=\mathrm{diag}(1,1,|\mathbf{U}_j^l||\mathbf{U}_j^r|)$。

得到刚体变换矩阵之后，模型中每一组分的参数估计与常规高斯混合模型参数的估计方法一样，可用如下公式计算得到

$$\boldsymbol{\mu}_k = \frac{\sum_{j=1}^{M}\sum_{i=1}^{N_j}\alpha_{jik}(\mathbf{T}_j\boldsymbol{v}_{ji}+\boldsymbol{s}_j)}{\sum_{j=1}^{M}\sum_{i=1}^{N_j}\alpha_{jik}}$$

$$\sigma_k = \frac{\sum_{j=1}^{M}\sum_{i=1}^{N_j}\alpha_{jik}||\mathbf{T}_j\boldsymbol{v}_{ji}+\boldsymbol{s}_j-\boldsymbol{\mu}_k||_2^2}{3\sum_{j=1}^{M}\sum_{i=1}^{N_j}\alpha_{jik}}$$

接着通过引入约束$\sum_{k=1}^{K+1}\pi_k = 1$得到混合权重的估计

$$\pi_k = \frac{1}{\eta}\sum_{j=1}^{M}\sum_{i=1}^{N_j}\alpha_{jik}, \quad \forall k \in \{1,\cdots,K\}$$

$$\pi_{K+1} = 1 - \sum_{k=1}^{K}\pi_k$$

其中$\eta = (\gamma+1)(N - \sum_{j=1}^{M}\sum_{i=1}^{N_j}\alpha_{jiK+1})$，$N = \sum_{i=1}^{N_j}$。

至此，模型参数的估计已全部完成，整体算法总结于算法1中（这边需要根据我在文档中的描述相应地去更改算法1中的步骤）。

Algorithm 1. Batch Joint Registration of Multiple Point Clouds (JRMPC-B)

Require: Initial parameter set Θ^0, number of components K, number of iterations Q.

$q \leftarrow 1$
repeat
  E-step:
    Use Θ^{q-1} to estimate posterior probabilities $\alpha_{jik}^q = P(Z_{ji}=k|\boldsymbol{v}_{ji};\Theta^{q-1})$, i.e., (8).
  M-rigid-step:
    Use α_{jik}^q, $\boldsymbol{\mu}_k^{q-1}$ and Σ_k^{q-1} to estimate $\mathbf{R}_j^q$ and $\boldsymbol{t}_j^q$, i.e., (12) and (14).
  M-GMM-step:
    Use α_{jik}^q, $\mathbf{R}_j^q$ and $\boldsymbol{t}_j^q$ to estimate the means $\boldsymbol{\mu}_k^q$, i.e., (15).
    Use α_{jik}^q, $\mathbf{R}_j^q$, $\boldsymbol{t}_j^q$ and $\boldsymbol{\mu}_k^q$ to estimate the covariances Σ_k^q, i.e., (16).
    Use α_{jik}^q to estimate the priors p_k^q, i.e., (18).
    $q \leftarrow q+1$
until $q > Q$ (or Θ's update is negligible)
return Θ^q